

Project sml 2

Malikan Bahy Ramadhan / 3338240019 / 4A

2026-06-05

```
# Panggil library
library(tidyverse)

## Warning: package 'tidyverse' was built under R version 4.4.3
## Warning: package 'ggplot2' was built under R version 4.4.3
## Warning: package 'tidyr' was built under R version 4.4.2
## Warning: package 'readr' was built under R version 4.4.3
## Warning: package 'purrr' was built under R version 4.4.3
## Warning: package 'dplyr' was built under R version 4.4.2
## Warning: package 'stringr' was built under R version 4.4.2
## Warning: package 'forcats' was built under R version 4.4.3
## Warning: package 'lubridate' was built under R version 4.4.3

## — Attaching core tidyverse packages — tidyverse
2.0.0 —
## ✓ dplyr      1.1.4      ✓ readr      2.1.5
## ✓ forcats   1.0.0      ✓ stringr    1.5.1
## ✓ ggplot2    4.0.2      ✓ tibble     3.2.1
## ✓ lubridate 1.9.4      ✓ tidyr      1.3.1
## ✓ purrr      1.2.2
## — Conflicts —
tidyverse_conflicts() —
## ✗ dplyr::filter() masks stats::filter()
## ✗ dplyr::lag()     masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all
conflicts to become errors

library(fpc)

## Warning: package 'fpc' was built under R version 4.4.3

library(cluster)

## Warning: package 'cluster' was built under R version 4.4.3

library(factoextra)
```

```

## Warning: package 'factoextra' was built under R version 4.4.3

## Welcome to factoextra!
## Want to learn more? See two factoextra-related books at
https://www.datanovia.com/en/product/practical-guide-to-principal-component-methods-in-r/

library(mclust)

## Warning: package 'mclust' was built under R version 4.4.3

## Package 'mclust' version 6.1.2
## Type 'citation("mclust")' for citing this R package in publications.
##
## Attaching package: 'mclust'
##
## The following object is masked from 'package:dplyr':
##
##     count
##
## The following object is masked from 'package:purrr':
##
##     map

library(dbSCAN)

## Warning: package 'dbSCAN' was built under R version 4.4.3

##
## Attaching package: 'dbSCAN'
##
## The following object is masked from 'package:fpc':
##
##     dbSCAN
##
## The following object is masked from 'package:stats':
##
##     as.dendrogram

#INPUT DATA
# Definisikan URL dan nama kolom
url_data <- "https://archive.ics.uci.edu/ml/machine-learning-databases/autos/imports-85.data"
nama_kolom <- c(
  "symboling", "normalized_losses", "make", "fuel_type", "aspiration",
  "num_of_doors", "body_style", "drive_wheels", "engine_location",
  "wheel_base",
  "length", "width", "height", "curb_weight", "engine_type",
  "num_of_cylinders", "engine_size", "fuel_system", "bore", "stroke",
  "compression_ratio", "horsepower", "peak_rpm", "city_mpg", "highway_mpg",
  "price"
)

```

```

# Membaca data
mobil <- read_csv(url_data, col_names = nama_kolom, na = "?")

## Rows: 205 Columns: 26
## — Column specification

```

```

## Delimiter: ","
## chr (10): make, fuel_type, aspiration, num_of_doors, body_style,
drive_wheel...
## dbl (16): symboling, normalized_losses, wheel_base, length, width, height,
c...
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this
message.

head(mobil) # Diubah ke head() agar tidak mencetak ribuan baris di Word

## # A tibble: 6 × 26
##   symboling normalized_losses make   fuel_type aspiration num_of_doors
##   <dbl>           <dbl> <chr> <chr>      <chr>      <chr>
## 1         3             NA alfa... gas        std        two
convertib...
## 2         3             NA alfa... gas        std        two
convertib...
## 3         1             NA alfa... gas        std        two
hatchback
## 4         2            164 audi   gas        std        four
sedan
## 5         2            164 audi   gas        std        four
sedan
## 6         2             NA audi   gas        std        two
sedan
## # i 19 more variables: drive_wheels <chr>, engine_location <chr>,
## #   wheel_base <dbl>, length <dbl>, width <dbl>, height <dbl>,
## #   curb_weight <dbl>, engine_type <chr>, num_of_cylinders <chr>,
## #   engine_size <dbl>, fuel_system <chr>, bore <dbl>, stroke <dbl>,
## #   compression_ratio <dbl>, horsepower <dbl>, peak_rpm <dbl>, city_mpg
<dbl>,
## #   highway_mpg <dbl>, price <dbl>

#PRE-PROCESSING
# A. Menghapus semua baris yang mengandung NA
auto_clean <- mobil %>% drop_na()

# Mengubah kolom karakter/kategorikal menjadi faktor

```

```
auto_clean_1 <- auto_clean %>% mutate(across(where(is.character), as.factor))
head(auto_clean_1)
```

```
## # A tibble: 6 × 26
##   symboling normalized_losses make   fuel_type aspiration num_of_doors
##   body_style
##   <dbl>          <dbl> <fct> <fct>      <fct>      <fct>
## 1         2         164 audi   gas      std        four
##   sedan
## 2         2         164 audi   gas      std        four
##   sedan
## 3         1         158 audi   gas      std        four
##   sedan
## 4         1         158 audi   gas      turbo       four
##   sedan
## 5         2         192 bmw    gas      std        two
##   sedan
## 6         0         192 bmw    gas      std        four
##   sedan
## # i 19 more variables: drive_wheels <fct>, engine_location <fct>,
## #   wheel_base <dbl>, length <dbl>, width <dbl>, height <dbl>,
## #   curb_weight <dbl>, engine_type <fct>, num_of_cylinders <fct>,
## #   engine_size <dbl>, fuel_system <fct>, bore <dbl>, stroke <dbl>,
## #   compression_ratio <dbl>, horsepower <dbl>, peak_rpm <dbl>, city_mpg
## #   <dbl>,
## #   highway_mpg <dbl>, price <dbl>
```

B. Scaling Data Numerik

```
auto_num <- auto_clean_1 %>% select(where(is.numeric))
auto_scale <- scale(auto_num)
head(auto_scale)
```

```
##   symboling normalized_losses wheel_base   length   width
##   height
## [1,]  1.0595642          1.202423  0.2972180  0.3632821  0.3041522
##      0.1765849
## [2,]  1.0595642          1.202423  0.2198099  0.3632821  0.4068278
##      0.1765849
## [3,]  0.2214015          1.034126  1.4583399  1.7604662  2.9737177
##      0.7936617
## [4,]  0.2214015          1.034126  1.4583399  1.7604662  2.9737177
##      0.8818155
## [5,]  1.0595642          1.987808  0.5681465  0.3806384 -0.4145769
##      0.1765849
## [6,] -0.6167613          1.987808  0.5681465  0.3806384 -0.4145769
##      0.1765849
##   curb_weight engine_size      bore      stroke compression_ratio
##   horsepower
## [1,] -0.2575798 -0.3357239 -0.4119383  0.5549495      -0.04142772
```

```

0.2006447
## [2,]  0.7529166  0.5506615 -0.4119383  0.5549495        -0.55563599
0.6238413
## [3,]  0.7944155  0.5506615 -0.4119383  0.5549495        -0.42708392
0.4610734
## [4,]  1.2965513  0.3865161 -0.6363753  0.5549495        -0.47850475
1.4376810
## [5,] -0.1372332 -0.3685530  0.7476527 -1.4797233        -0.34995268
0.1680912
## [6,] -0.1372332 -0.3685530  0.7476527 -1.4797233        -0.34995268
0.1680912
##      peak_rpm  city_mpg highway_mpg    price
## [1,] 0.8291132 -0.4136385 -0.3222945 0.4260517
## [2,] 0.8291132 -1.3977060 -1.5608401 1.0215069
## [3,] 0.8291132 -1.2336948 -1.0963855 1.0657407
## [4,] 0.8291132 -1.5617173 -1.8704765 2.1145925
## [5,] 1.4732289 -0.5776497 -0.4771127 0.8479742
## [6,] 1.4732289 -0.5776497 -0.4771127 0.9321886

```


PROSES CLUSTERING & PENENTUAN K OPTIMAL

1. VISUALISASI ELBOW METHOD

```

fviz_nbclust(auto_scale, kmeans, method = "wss") +
  labs(subtitle = "Elbow Method")

```



2. VISUALISASI SILHOUETTE METHOD


```

fviz_nbclust(auto_scale, kmeans, method = "silhouette") +
  labs(subtitle = "Silhouette Method")

```

Optimal number of clusters (method = "silhouette")

Silhouette Method




```
# METODE PARTITIONING CLUSTERING (K-Means)
set.seed(123) # Mengunci random state agar hasil konsisten
km_model <- kmeans(auto_scale, centers = 2)


# Melihat jumlah anggota tiap cluster
table(km_model$cluster)

##
##  1  2
## 56 103

# Visualisasi Hasil K-Means
fviz_cluster(km_model, data = auto_scale, geom = "point",
              main = "K-Means Clustering (2 Centers)")
```



```
# METODE DBSCAN  
# 1. Tentukan nilai EPS (mencari knee-point/titik siku)  
dbscan::kNNdistplot(auto_scale, k = 2)  
abline(h = 3.5, col = "red", lty = 2)
```




```
# 2. Jalankan DBSCAN
db_model <- dbscan::dbscan(auto_scale, eps = 3.5, minPts = 2)

# Melihat hasil cluster (0 = noise/outlier)
table(db_model$cluster)

##
##    0    1    2    3    4    5
##  3 139    2    5    7    3

# Visualisasi DBSCAN
fviz_cluster(db_model, data = auto_scale, geom = "point",
              main = "DBSCAN Clustering")
```

```
# PROSES MODEL-BASED CLUSTERING (GMM)
# Menjalankan GMM menggunakan fungsi Mclust()
gmm_model <- Mclust(auto_scale)

# Menampilkan ringkasan hasil pemodelan
summary(gmm_model)


## -----
## Gaussian finite mixture model fitted by EM algorithm
## -----
##
## Mclust VVV (ellipsoidal, varying volume, shape, and orientation) model
with 2
## components:
##
##   log-likelihood    n  df      BIC      ICL
##      -1453.033 159 305 -4452.082 -4452.377
##
## Clustering table:
##   1  2
## 88 71

# Mengambil label cluster untuk setiap baris data
gmm_clusters <- gmm_model$classification

# Melihat jumlah mobil di tiap cluster
table(gmm_clusters)
```

```
## gmm_clusters
## 1 2
## 88 71

# Visualisasi hasil clustering GMM
fviz_cluster(gmm_model, geom = "point",
             main = "Model-Based Clustering")
```



```
# PROSES SPECTRAL CLUSTERING
# Langkah 1: Menghitung Similarity Matrix
similarity_matrix <- exp(-as.matrix(dist(auto_scale))^2)

# Langkah 2 & 3: Melakukan Dekomposisi Spektra
eigen_result <- eigen(similarity_matrix)

# Menentukan jumlah cluster (k = 2)
k <- 2

# Mengekstrak top-k eigenvectors
k_eigenvectors <- eigen_result$vectors[, 1:k]

# Langkah 4: Melakukan K-Means Clustering pada Eigenvectors
set.seed(123)
cluster_assignments <- kmeans(k_eigenvectors, centers = k)

# Mengambil label cluster untuk setiap baris data mobil
spectral_clusters <- cluster_assignments$cluster
```


```

# Melihat jumlah mobil di tiap cluster
table(spectral_clusters)

## spectral_clusters
##    1    2
## 138  21

# Visualisasi hasil Spectral Clustering
fviz_cluster(list(data = auto_scale, cluster = spectral_clusters),
              geom = "point",
              main = "Spectral Clustering (k = 2)")

```



```

# VALIDASI INTERNAL (SILHOUETTE WIDTH)
# Membuat matriks jarak Euclidean dari data numerik asli sebagai basis
# validasi
jarak_validasi <- dist(auto_scale)

# Menghitung statistik validasi untuk masing-masing model menggunakan
cluster.stats()
# Bagian validasi di bawah ini disesuaikan dengan objek cluster dari
# pemodelan di atas
val_km <- cluster.stats(jarak_validasi, km_model$cluster)
val_db <- cluster.stats(jarak_validasi, db_model$cluster)

## Warning in cluster.stats(jarak_validasi, db_model$cluster): clustering
## renumbered because maximum != number of clusters

```

```

val_gmm <- cluster.stats(jarak_validasi, gmm_clusters)
val_spec <- cluster.stats(jarak_validasi, spectral_clusters)

# Menggabungkan nilai Average Silhouette Width ke dalam satu tabel
tabel_validasi <- data.frame(
  Metode_Clustering = c("K-Means", "DBSCAN", "Model-Based (GMM)", "Spectral
Clustering"),
  Avg_Silhouette_Score = c(val_km$avg.silwidth, val_db$avg.silwidth,
val_gmm$avg.silwidth, val_spec$avg.silwidth)
)

# Menampilkan hasil perbandingan skor validasi
print("--- HASIL PERBANDINGAN VALIDASI INTERNAL (SILHOUETTE WIDTH) ---")
## [1] "--- HASIL PERBANDINGAN VALIDASI INTERNAL (SILHOUETTE WIDTH) ---"
knitr::kable(tabel_validasi)

```

Metode_Clustering	Avg_Silhouette_Score
K-Means	0.3289528
DBSCAN	0.1698303
Model-Based (GMM)	0.2230576
Spectral Clustering	-0.0143908


```

# VISUALISASI PERBANDINGAN MODEL
# Mengatur tampilan plot menjadi 2 baris dan 3 kolom agar bisa dilihat
bersamaan
par(mfrow = c(2, 3))

# Plot 2: K-Means
fviz_cluster(list(data = auto_scale, cluster = km_model$cluster), geom =
"point", main = "2. K-Means (k=2)")

```


2. K-Means (k=2)



Plot 3: DBSCAN


```
fviz_cluster(list(data = auto_scale, cluster = db_model$cluster), geom =  
"point", main = "3. DBSCAN (eps=3.5)")
```

3. DBSCAN (eps=3.5)



```
# Plot 4: Model-Based (GMM)
```


```
fviz_cluster(gmm_model, geom = "point", main = "4. Model-Based GMM (G=2)")
```



```
# Plot 5: Spectral Clustering
```

```
fviz_cluster(list(data = auto_scale, cluster = spectral_clusters), geom =  
"point", main = "5. Spectral Clustering (k=2)")
```

5. Spectral Clustering (k=2)



```
# Mengembalikan pengaturan plot ke default  
par(mfrow = c(1, 1))
```

BAB I: INPUT DATA DAN SUMBER DATA

Analisis pengelompokan (clustering) ini menggunakan dataset publik Automobile/Imports 1985 yang diperoleh langsung dari UCI Machine Learning Repository. Dataset ini berisi karakteristik fisik, teknis mekanis, serta estimasi harga dari berbagai spesifikasi mobil.

Proses input data dilakukan secara real-time di R menggunakan fungsi `read_csv()` dengan mendefinisikan 26 nama kolom secara manual guna memberikan struktur tabel yang jelas. Tanda tanya (?) pada data mentah secara eksplisit didefinisikan sebagai nilai hilang (NA) agar tidak mengacaukan tipe data.

BAB II: PRE-PROCESSING DATA DAN JUSTIFIKASI SCALING

Sebelum algoritma clustering dijalankan, data melalui dua tahapan kritis pre-processing:

1. Penanganan Missing Values (Drop NA): Guna menjaga objektivitas dan pemisahan spasial yang akurat, seluruh baris data yang mengandung missing values (NA) dieliminasi menggunakan fungsi `drop_na()`.
2. Justifikasi Pentingnya Scaling (Standarisasi Z-Score): Dataset ini didominasi oleh variabel numerik yang memiliki satuan dan rentang nilai yang sangat timpang. Sebagai contoh, variabel harga (price) memiliki nilai hingga puluhan ribu, kapasitas tenaga (horsepower) bernilai ratusan, sedangkan dimensi tinggi kendaraan (height) hanya bernilai puluhan. Jika data langsung digunakan tanpa transformasi,

perhitungan jarak Euclidean pada algoritma K-Means atau DBSCAN akan didominasi secara mutlak oleh variabel berangka besar (price), sehingga variabel dimensi fisik yang krusial akan diabaikan. Oleh karena itu, opsi menggunakan scaling manual lewat fungsi `scale()` wajib dilakukan. Transformasi ini menyamakan rata-rata (mean) menjadi 0 dan standar deviasi menjadi 1 untuk seluruh fitur numerik, sehingga setiap variabel berkontribusi secara adil (equal weight) dalam pembentukan kluster.

BAB III: PENENTUAN JUMLAH CLUSTER OPTIMAL (K)

Untuk menentukan jumlah kelompok (k) yang paling merepresentasikan struktur data, digunakan dua pendekatan eksploratif:

1. Elbow Method (Metode Siku): Berdasarkan grafik Total Within Sum of Square (WCSS) yang dieksekusi, terjadi penurunan variansi internal yang sangat drastis dan curam dari $k = 1$ ke $k = 2$. Tepat di titik $k = 2$, sudut grafik melandai secara signifikan (membentuk lekukan siku). Penambahan cluster ke angka 3 dan seterusnya memberikan penurunan yang relatif konstan dan lambat. Hal ini mengindikasikan bahwa secara mekanis, pembagian data menjadi 2 kelompok sudah sangat efisien.
2. Silhouette Method: Selaras dengan metode Elbow, grafik rata-rata Silhouette Score yang dihasilkan menunjuk langsung bahwa puncak tertinggi (skor kohesi dan separasi spasial terbaik) berada pada jumlah cluster $k = 2$.

Kesimpulan Tahap Eksplorasi: Melalui konvergensi hasil Elbow dan Silhouette, maka jumlah cluster ditetapkan sebanyak $k = 2$.

BAB IV: ANALISIS DAN VALIDASI INTERNAL MODEL

Setelah memproses data numerik hasil scaling ke dalam beberapa algoritma machine learning dengan parameter $k = 2$, efektivitas pembentukan kelompok diuji menggunakan kriteria Average Silhouette Width (validasi internal) lewat fungsi `cluster.stats()`:

- K-Means Clustering: Menghasilkan skor tertinggi sebesar 0.3289. Hal ini membuktikan bahwa algoritma K-Means berhasil mengelompokkan data secara solid dengan batas antar kelompok yang paling jelas pada ruang metrik Euclidean.
- Model-Based Clustering (GMM): Menghasilkan skor 0.2230. Pemodelan probabilistik berbasis distribusi campuran Gaussian ini bekerja cukup baik, namun masih di bawah performa K-Means.
- DBSCAN: Menghasilkan skor 0.1698. Nilai ini lebih rendah karena DBSCAN mendeteksi beberapa data pencilan sebagai noise (Cluster 0), yang secara otomatis mengurangi nilai rata-rata kekuatan kluster secara global.
- Spectral Clustering: Menghasilkan skor negatif yaitu -0.0143. Nilai di bawah 0 menandakan terjadinya banyak misclustering (data berada di batas kluster yang

salah), sehingga dekomposisi graf tidak direkomendasikan untuk karakteristik dataset ini.

BAB V: INTERPRETASI DAN PROFILING CLUSTER (MODEL TERBAIK: K-MEANS)

Karena K-Means terbukti sebagai model dengan performa struktur terbaik (skor 0.3289), interpretasi karakteristik riil difokuskan pada hasil partisi K-Means. Algoritma secara natural membagi kendaraan menjadi dua segmen pasar yang bertolak belakang:

1. Cluster 1: Kelompok Mobil Kota / Ekonomis (City Car & Kompak)
 - Karakteristik Fisik: Mobil-mobil pada klaster ini memiliki dimensi fisik yang kompak (panjang, lebar, dan jarak sumbu roda yang kecil) serta bobot kendaraan (curb_weight) yang cenderung ringan.
 - Performa Mekanis: Dibekali dengan kapasitas mesin (engine size) yang kecil, jumlah silinder yang sedikit, serta tenaga kuda (horsepower) yang rendah hingga moderat.
 - Efisiensi Bahan Bakar: Memiliki nilai mil per galon harian (city_mpg) dan luar kota (highway_mpg) yang sangat tinggi. Cluster ini merepresentasikan barisan kendaraan yang sangat hemat bahan bakar.
 - Nilai Ekonomis: Memiliki tingkat kerugian penyusutan risiko yang stabil (normalized_losses) dan dipasarkan pada rentang harga (price) yang murah dan ekonomis.
2. Cluster 2: Kelompok Mobil Mewah & Performa Tinggi (Luxury Executive & Sports Car)
 - Karakteristik Fisik: Memiliki karakteristik bodi yang bongsor dan kokoh (jarak sumbu roda panjang, bodi lebar) serta bobot kendaraan (curb_weight) yang berat karena material premium dan kompleksitas komponen pendukung.
 - Performa Mekanis: Memiliki jantung mekanis yang agresif dengan ukuran mesin besar (engine_size), jumlah silinder banyak, serta letupan tenaga kuda (horsepower) yang masif untuk mengejar kecepatan tinggi.
 - Efisiensi Bahan Bakar: Nilai city_mpg dan highway_mpg berada pada tingkat yang sangat rendah (konsumsi bahan bakar cenderung boros akibat kompensasi performa mesin).
 - Nilai Ekonomis: Menempati segmen pasar premium dengan harga jual (price) yang tinggi/mahal. Cluster ini mengelompokkan mobil-mobil kelas atas (luxury) dan varian sport.

BAB VI: KESIMPULAN

Berdasarkan rangkaian analisis statistik yang telah dilakukan pada dataset Imports 1985, keputusan untuk menggunakan scaling data adalah langkah pre-processing yang krusial untuk menghilangkan bias akibat ketimpangan satuan angka variabel numerik.

Melalui pengujian parameter, disimpulkan bahwa jumlah kelompok terbaik adalah $k = 2$. Berdasarkan metrik validasi internal, K-Means Clustering dinobatkan sebagai algoritma paling optimal dengan kemampuan segmentasi terbaik (skor 0.3289). Hasil klasterisasi ini secara nyata berhasil memetakan industri otomotif tahun 1985 menjadi dua kutub fungsional, yaitu kelompok kendaraan harian yang efisien/ekonomis (Cluster 1) dan kelompok kendaraan premium dengan performa mekanis tinggi (Cluster 2).